Łańcuchy Markowa – randomizowany algorytm dla problemu 2-SAT.

Procesem stochastycznym – zbiór zmiennych losowych $\{X(t) : t \in T\}$
Proces jest **skończony** jeśli zmienne X_t przyjmują skończenie wiele wartości.

Proces Markowa – proces stochastyczny $X_0, X_1, X_2, \ldots$ taki, że dla dowolnego t zachodzi

$$P(X_t = a_t \mid X_{t-1} = a_{t-1}, X_{t-2} = a_{t-2}, \ldots X_0 = a_0) = P(X_t = a_t \mid X_{t-1} = a_{t-1})$$

Rozkład X_t jest w pełni zdeterminowany przez X_{t-1}, które zawiera wszystkie informacje o poprzednich stanach – łańcuch Markowa jest bez pamięci.

Macierz przejścia – macierz $\mathbf{P}$ taka, że:

$$P_{i,j} = P(X_t = j \mid X_{t-1} = i) \qquad \forall_i \sum_j P_{i,j} = 1$$

Rozkład stacjonarny – wektor $\bar{\pi}$ taki, że $\bar{\pi} = \bar{\pi}\mathbf{P}$ oraz $\sum_i \bar{\pi}_i = 1$

Problem 2-SAT

Mamy n zmiennych i k klauzul postaci $a \vee b$, gdzie $a = x_i$ albo $a = \bar{x}_i$.

Algorytm

Ustalamy $\lambda \in \mathbb{N}^+$.

1. Wylosuj dowolne wartościowanie zmiennych $x_1, \ldots, x_n$.
2. Powtarzaj co najwyżej $2\lambda n^2$ razy lub do znalezienia rozwiązania.
   (a) Wylosuj niespełnioną klauzulę.
   (b) Wylosuj literał z tej klauzuli i odwróć wartość.
3. Jeśli wartościowanie spełnia formułę, to jest odpowiedź.
4. Wpp uznaj, że formuła jest niespełnialna.

Algorytm jest wolniejszy od rozwiązania za pomocą silnie spójnych składowych, które ma złożoność $(n + k)$.

Twierdzenie. Jeśli formuła jest spełnialna, to oczekiwana liczba kroków wynosi co najwyżej n^2.

Dowód. Modelujemy zachowanie algorytmu jako łańcuch Markowa.

S – dowolne wartościowanie, które spełnia formułę
A_i – wartościowanie wygenerowane przez algorytm w i-tym kroku
X_i – liczba zmiennych o tym samym wartościowanie w S i w A_i

Proces $\{X_i\}$ nie jest łańcuchem Markowa, bo prawdopodobieństwo przejścia z X_i do X_{i+1} jest zadane wartościowaniem A_i, które nie jest częścią łańcucha.

Definiujemy proces $Y_0, Y_1, \ldots$, który jest łańcuchem Markowa i modeluje pesymistyczny przebieg algorytmu.

Jeśli klauzula nie jest spełniona, to wartościowania A_i oraz S wartościują co najmniej jedną z jej zmiennych inaczej. W takim razie

$$P(X_{i+1} = j + 1 \mid X_i = j) \geq \frac{1}{2}$$

$$P(X_{i+1} = j - 1 \mid X_i = j) \leq \frac{1}{2}$$

Zatem w pesymistycznej sytuacji:

$$Y_0 = X_0$$

$$P(Y_{i+1} = 1 \mid Y_i = 0) = 1$$

$$P(Y_{i+1} = j + 1 \mid Y_i = j) = P(Y_{i+1} = j - 1 \mid Y_i = j) = \frac{1}{2}$$

Niech Z_i oznacza liczbę kroków potrzebną do pierwszego dotarcia do stanu n, zaczynając w stanie i.

$$h_i = \mathbb{E}[Z_i] = \mathbb{E}\left[1 + \frac{Z_{i-1}}{2} + \frac{Z_{i+1}}{2}\right]$$

Dostajemy układ $n + 1$ równań:

$$\begin{cases} h_0 = h_1 + 1 \\ h_i = 1 + \frac{1}{2}(h_{i-1} + h_{i+1}), \text{ czyli } h_{i+1} = 2h_i - h_{i-1} - 2 \\ h_n = 0 \end{cases}$$

Rozwiązując indukcyjnie, otrzymujemy:

$$\begin{aligned} h_1 &= h_0 - 1 \\ h_2 &= 2h_1 - h_0 - 2 = h_1 - 3 = h_0 - 1 - 3 \\ h_3 &= 2h_2 - h_1 - 2 = h_2 - 5 = h_0 - 1 - 3 - 5 \\ h_i &= h_0 - i^2 \end{aligned}$$

W takim razie $h_n = 0 = h_0 - n^2$, czyli $h_0 = n^2$ – start w stanie 0 jest najbardziej pesymistyczny. □

Twierdzenie. Jeśli formuła jest spełnialna, to algorytm myli się z prawdopodobieństwem $2^{-\lambda}$.

Dowód. Dzielimy wykonanie algorytmu na bloki długości $2n^2$. Niech Z_i oznacza liczbę kroków wykonaną od początku i-tego bloku. Z nierówności Markowa:

$$P(Z_i > 2n^2) \leq \frac{n^2}{2n^2} = \frac{1}{2}$$

Prawdopodobieństwo, że po λ blokach algorytm nie znalazł wartościowania nie przekracza $2^{-\lambda}$. □

Problem kul i urn ze wzmocnionym feedbackiem.

Rozkład wykładniczy z parametrem λ – rozkład zadany dystrybuantą

$$F(x) = \begin{cases} 1 - e^{-\lambda x} & \text{dla } x \geq 0 \\ 0 & \text{dla } x < 0 \end{cases}$$

Gęstość rozkładu wykładniczego to $f(x) = \lambda e^{-\lambda x}$.

$$\mathbb{E}[X] = \int_0^\infty x\lambda e^{-\lambda x} x = \frac{1}{\lambda} \qquad M_X(t) = \frac{\lambda}{\lambda - t}$$

$$\mathrm{Var}[X] = \mathbb{E}\left[X^2\right] - \mathbb{E}[X]^2 = \frac{1}{\lambda^2}$$

Rozkład wykładniczy jest **bez pamięci**:

$$P(X > s + t \mid X > t) = P(X > s)$$

Kule i urny z feedbackiem

Mamy dwie urny, a im więcej kul jest w urnie, tym większa szansa na dorzucenie kolejnej. Jeśli w pierwszej urnie jest x kul a w drugiej y to prawdopodobieństwo, że kolejna kula trafi do pierwszej urny wynosi

$$\frac{x^p}{x^p + y^p}$$

dla ustalonego $p > 1$.

Twierdzenie. Dla dowolnego $p > 1$ oraz dowolnych warunków początkowych, z prawdopodobieństwem 1 od pewnego momentu kule wpadają tylko do jednej urny.

Dowód. Przyjmujemy, że w obu urnach na początku jest po jednej kuli. Definiujemy proces pomocniczy – każda urna dostaje niezależny licznik czasu do otrzymania kolejnej kuli.

Jeśli w pierwszej urnie jest x kul, to czas oczekiwania na kolejną wynosi $T_x \sim \mathrm{Pois}(x^p)$. Podobnie $U_y \sim \mathrm{Pois}(y^p)$. Prawdopodobieństwo, że kolejna kula ląduje w pierwszej urnie wynosi dokładnie

$$\frac{x^p}{x^p + y^p},$$

czyli proces odpowiada oryginalnemu.

Definiujemy czasy nasycenia – po jakim czasie liczba kul w urnach jest dowolnie duża.

$$F_1 = \sum_{i=1}^{\infty} T_i \qquad F_2 = \sum_{i=1}^{\infty} U_i$$

Możemy tak zrobić, bo $\mathbb{E}[T_i] = \mathbb{E}[U_i] = \frac{1}{i^p}$, a ponieważ $p > 1$ to $\mathbb{E}[F_1]$ oraz $\mathbb{E}[F_2]$ są skończone.

Lemat (pomocniczy)**.** Jeśli X jest zmienną losową taką, że $\mathbb{E}[X] < \infty$, to $P(X < \infty) = 1$.

Dowód. Z nierówności Markowa:

$$\lim_{n\to\infty} P(X \geq n) \leq \lim_{n\to\infty} \frac{\mathbb{E}[X]}{n} = 0$$

$\square$

Zatem wartości F_1, F_2 są skończone i z prawdopodobieństwem 1 są różne.
Bez straty ogólności przyjmujemy, że $F_2 > F_1$. Oznacza to, że dla pewnego n

$$\sum_{i=1}^{n} U_i < F_1 < \sum_{i=1}^{n+1} U_i$$

Dla wystarczająco dużych m

$$\sum_{i=1}^{n} U_i < \sum_{i=1}^{m} T_i < \sum_{i=1}^{n+1} U_i,$$

czyli pierwsza urna zawiera m kul, a druga urna n kul. Z prawdopodobieństwem 1 druga urna utknęła na posiadaniu n kul, co było do pokazania. □

Liczba porównań w algorytmie quicksort.

Twierdzenie. Oczekiwana liczba porównań w algorytmie quicksort z jednostajnym i niezależnym losowaniem pivota wynosi $2n \ln n + \mathcal{O}(n)$.

Dowód.

$x_1, \ldots, x_n$ – wejściowy ciąg, $x_i \neq x_j$
$y_1, \ldots y_n = \text{sort}(x_1, \ldots x_n)$

$$X_{i,j} = \begin{cases} 1 & y_i, y_j \text{ porównane} \\ 0 & \text{wpp.} \end{cases} \quad \text{dla } i < j$$

Łączna liczba porównań: $X = \sum_{i=0}^{n-1} \sum_{j=i+1}^{n} X_{i,j}$

Oczekiwana liczba porównań: $\mathbb{E}[X] = \sum_{i=0}^{n-1} \sum_{j=i+1}^{n} \mathbb{E}[X_{i,j}]$

Elementy y_i, y_j są porównywane, jeśli któryś z nich jest pivotem i w momencie tego wyboru są w tej samej podtablicy. Niech $Y_{i,j} = \{y_i, \ldots, y_j\}$.

Jeśli pivot jest z $Y_{i,j}$ i różny od $y_i,\ y_j$, to te elementy już nigdy nie zostaną porównane:

$$X_{i,j} = 1 \iff \text{pierwszym pivotem z } Y^{i,j} \text{ jest } y_i \text{ lub } y_j$$

Prawdopodobieństwo, że wybierzemy y_1 lub y_j wynosi $\frac{2}{j-i+1}$, czyli $\mathbb{E}[X_{i,j}] = \frac{2}{j-i+1}$.

$$\begin{aligned}
\mathbb{E}[X] &= \sum_{i=1}^{n-1} \sum_{j=i+1}^{n} \frac{2}{j-i+1} \\
&= 2 \sum_{i=1}^{n-1} \sum_{k=2}^{n-i+1} \frac{1}{k} = 2 \sum_{k=2}^{n} \sum_{i=1}^{n-k+1} \frac{1}{k} \\
&= 2 \sum_{k=2}^{n} \frac{n+1-k}{k} \\
&= 2\left((n+1) \sum_{k=2}^{n} \frac{1}{k}\right) - 2(n-1) = 2\left((n+1)\left(\sum_{k=1}^{n} \frac{1}{k}\right) - (n+1)\right) - 2(n-1)
\end{aligned}$$

Podstawiając $\sum_{k=1}^{n} \frac{1}{k} = H_n = \ln n + \Theta(1)$, dostajemy:

$$\mathbb{E}[X] = 2(n+1) \cdot H_n - \Theta(n) = 2n \ln n + \Theta(n)$$

□

Igłę długości l rzucono na podłogę z desek o szerokości d, dla $l \leq d$. Jakie jest prawdopodobieństwo, że igła przetnie krawędź deski?

Twierdzenie. Prawdopodobieństwo, że igła przetnie którąś z krawędzi wynosi $\frac{2l}{d\pi}$.

Dowód.
$X \sim \mathrm{Unif}\big(\big[0, \frac{d}{2}\big]\big)$ – odległość od środka igły do najbliższej krawędzi deski
$\theta \sim \mathrm{Unif}\big(\big[0, \frac{\pi}{2}\big]\big)$ – kąt ostry pomiędzy igłą a krawędzią deski

Zmienne X i θ są niezależne, więc ich wspólny rozkład prawdopodobieństwa jest iloczynem:

$$f(x,\theta) = \begin{cases} \frac{4}{d\pi} & 0 \leq x \leq \frac{d}{2}, 0 \leq \theta \leq \frac{\pi}{2} \\ 0 & \text{wpp} \end{cases}$$

Igła przecina krawędź, gdy:

$$\frac{l}{2} \geq y = \frac{x}{\cos\theta}, \quad \text{czyli} \quad x \leq \frac{l \cdot \cos\theta}{2}$$

Obliczamy prawdopodobieństwo:

$$\int_{\theta=0}^{\frac{\pi}{2}} \int_{x=0}^{\frac{l}{2}\cos\theta} \frac{4}{d\pi}\, dx\, d\theta = \frac{4}{d\pi} \int_{\theta=0}^{\frac{\pi}{2}} \int_{x=0}^{\frac{l}{2}\cos\theta} 1\, dx\, d\theta =$$

$$\frac{4}{d\pi} \int_{\theta=0}^{\frac{\pi}{2}} \frac{l}{2} \cos\theta\, d\theta = \frac{2l}{d\pi} \int_{\theta=0}^{\frac{\pi}{2}} \cos\theta\, d\theta =$$

$$\frac{2l}{d\pi}\Big|_{\theta=0}^{\frac{\pi}{2}} \sin\theta = \frac{2l}{d\pi} \cdot \left(\sin\frac{\pi}{2} - \sin 0\right) = \boxed{\frac{2l}{d\pi}}$$

□

Pionek zaczyna w $(0,0)$. W i-tym kroku przesuwa się z aktualnej pozycji o wektor jednostkowy pod kątem α_i wylosowany jednostajnie z $[0, 2\pi]$. Jaki jest oczekiwany kwadrat odległości od punktu $(0,0)$ po n krokach?

Losujemy:

- $\alpha_i \in [0, 2\pi]$ – kąt
- $\beta_i^x, \beta_i^y\ in\{-1, 1\}$ – kierunek w x, y

(x_i, y_i) – przesunięcie w i-tym kroku

$x_i = \beta_i^y \cdot \cos(\alpha_i)$

$y_i = \beta_i^x \cdot \sin(\alpha_i)$

Położenie po n krokach:

$$X = \sum_{i=1}^{n} x_i \qquad Y = \sum_{i=1}^{n} y_i$$

$$\mathbb{E}\big[X^2 + Y^2\big] = \mathbb{E}\left[\left(\sum_{i=1}^{n} x_i\right)^2\right] + \mathbb{E}\left[\left(\sum_{i=1}^{n} y_i\right)^2\right] = \mathbb{E}\left[\sum_{i=1}^{n} x_i^2 + y_i^2\right] + \mathbb{E}\left[\sum_{i \neq j} x_i x_i\right] + \mathbb{E}\left[\sum_{i \neq j} y_i y_i\right] =$$

$$n + \mathbb{E}\left[\sum_{i \neq j} \beta_i^y \beta_j^y \cdot \sin(\alpha_i)\sin(\alpha_j)\right] + \mathbb{E}\left[\sum_{i \neq j} \beta_i^x \beta_j^x \cdot \cos(\alpha_i)\cos(\alpha_j)\right] = n \longleftarrow \text{kwadrat odległości}$$

Niech $(N(t), t \geq 0)$ będzie procesem Poissona o parametrze λ. Wykazać, że jeśli w przedziale $(0, t]$ zaszło dokładnie jedno zdarzenie, to czas zajścia tego zdarzenia (X_1) ma rozkład jednostajny na $(0, t]$.

Proces Poissona z parametrem λ – proces stochastyczny $\{N(t) \mid t \in \mathbb{R}, t \geq 0\}$ taki, że:

1. $N(0) = 0$
2. Rozłączne przedziały są niezależne: $(N(a) - N(b)) \perp (N(c) - N(d))$ dla $[b, a] \cap [d, c] = \varnothing$
3. Liczba zdarzeń na przedziałach jest stacjonarna: $(N(t+s) - N(s)) \sim N(t)$
4. $\lim_{t \to 0} \frac{P(N(t)=1)}{t} = \lambda$
5. $\lim_{t \to 0} \frac{P(N(t)>1)}{t} = 0$

Intuicyjnie: $N(t)$ mówi, ile zdarzeń zaszło od momentu rozpoczęcia procesu do chwili t.

Twierdzenie. Niech $\{N(t) \mid t \geq 0\}$ będzie procesem Poissona z parametrem λ. Dla dowolnego $t \geq 0$ i $n \in \mathbb{N}$:

$$P_n(t) = P(N(t) = n) = e^{-\lambda t} \frac{(\lambda t)^n}{n!}$$

Dowód indukcyjny. Z niezależności rozłącznych przedziałów mamy:

$$P_0(t+h) = P_0(t) \cdot P_0(h)$$

$$\begin{aligned}
P_0'(t) &= \lim_{h \to 0} \frac{P_0(t+h) - P_0(t)}{h} = \lim_{h \to 0} P_0(t) \cdot \frac{P_0(h) - 1}{h} \\
&= \lim_{h \to 0} P_0(t) \cdot \frac{1 - P(N(h) = 1) - P(N(h) > 1) - 1}{h} \\
&= \lim_{h \to 0} \left(P_0(t) \cdot \left(\frac{-P(N(h) = 1)}{h} - \frac{P(N(h) > 1)}{h} \right) \right) \\
&= P_0(t) \cdot \left(- \lim_{h \to 0} \frac{P(N(h) = 1)}{h} - \lim_{h \to 0} \frac{P(N(h) > 1)}{h} \right) \\
&= P_0(t) \cdot (-\lambda - 0) = -\lambda P_0(t)
\end{aligned}$$

Dostajemy równanie różniczkowe

$$P_0'(t) = -\lambda P_0(t) \quad \to \quad \frac{P_0'(t)}{P_0(t)} = -\lambda$$

Rozwiązanie:

$$\ln P_0(t) = -\lambda t + C$$

$$P_0(t) = e^{-\lambda t + C}$$

Ponieważ $P_0(0) = 1$, to $C = 0$, czyli $P_0(t) = e^{-\lambda t}$ – baza indukcji działa.

$$\begin{aligned}
P_n(t+h) &= \sum_{k=0}^{n} P_{n-k}(t) \cdot P_k(h) \\
&= P_n(t) \cdot P_0(h) + P_{n-1}(t) \cdot P_1(h) + \sum_{k=2}^{n} P_{n-k}(t) \cdot P(N(h) = k)
\end{aligned}$$

$$
\begin{aligned}
P_n'(t) &= \lim_{h\to 0} \frac{P_n(t+h) - P_n(t)}{h} \\
&= \lim_{h\to 0} \left(\frac{P_n(t)\cdot P_0(h) + P_{n-1}(t)\cdot P_1(h) + \sum_{k=2}^{n}(P_{n-k}(t)\cdot P(N(h)=k)) - P_n(t)}{h} \right) \\
&= \lim_{h\to 0} \left(\frac{P_n(t)\cdot (P_0(h)-1) + P_{n-1}(t)\cdot P(N(h)=1) + \sum_{k=2}^{n} P_{n-k}(t)\cdot P(N(h)=k)}{h} \right) \\
&= \lim_{h\to 0} \left(\frac{P_n(t)\cdot (P_0(h)-1)}{h} + \frac{P_{n-1}(t)\cdot P(N(h)=1)}{h} + \sum_{k=2}^{n} P_{n-k}(t)\cdot \frac{P(N(h)=k)}{h} \right) \\
&= P_n(t) \lim_{h\to 0} \left(\frac{P_0(h)-1}{h} \right) + P_{n-1}(t) \lim_{h\to 0} \left(\frac{P(N(h)=1)}{h} \right) + \sum_{k=2}^{n} P_{n-k}(t)\cdot \lim_{h\to 0} \left(\frac{P(N(h)=k)}{h} \right) \\
&= P_n(t) \lim_{h\to 0} \left(\frac{1 - \mathrm{P}(N(h)=1) - \mathrm{P}(N(h)=2) - 1}{h} \right) + P_{n-1}(t)\cdot \lambda + \sum_{k=2}^{n} P_{n-k}(t)\cdot 0 \\
&= P_n(t) \left(-\lim_{h\to 0} \frac{\mathrm{P}(N(h)=1)}{h} - \lim_{h\to 0} \frac{\mathrm{P}(N(h)=2)}{h} \right) + \lambda P_{n-1}(t) \\
&= -\lambda P_n(t) + \lambda P_{n-1}(t)
\end{aligned}
$$

Znowu dostajemy równanie różniczkowe:

$$
\begin{aligned}
P_n'(t) &= -\lambda P_n(t) + \lambda P_{n-1}(t) \\
e^{\lambda t} P_n'(t) + e^{\lambda t} \lambda P_n(t) &= \lambda e^{\lambda t} P_{n-1}(t) \\
\frac{d}{dt}\left(e^{\lambda t}\cdot P_n(t)\right) &= \lambda e^{\lambda t} P_{n-1}(t)
\end{aligned}
$$

Z założenia indukcyjnego: $\frac{d}{dt}\left(e^{\lambda t}\cdot P_n(t)\right) = \lambda e^{\lambda t}\cdot e^{-\lambda t}\cdot \frac{(\lambda t)^{n-1}}{(n-1)!} = \frac{\lambda^n \cdot t^{n-1}}{(n-1)!}$

Całkujemy obustronnie:

$$
\int \frac{d}{dt}\left(e^{\lambda t} P_n(t)\right)\, dt = e^{\lambda t} P_n(t) + C_1
$$

$$
\int \frac{\lambda^n \cdot t^{n-1}}{(n-1)!}\, dt = \frac{\lambda^n}{(n-1)!}\cdot \int t^{n-1}\, dt = \frac{\lambda^n}{(n-1)!}\cdot \frac{t^n}{n} + C_2 = \frac{\lambda^n t^n}{n!} + C_2
$$

$$
\begin{aligned}
e^{\lambda t} P_n(t) + C_1 &= \frac{\lambda^n t^n}{n!} + C_2 \\
e^{\lambda t} P_n(t) &= \frac{\lambda^n t^n}{n!} + C \quad (C = C_2 - C_1) \\
P_n(t) &= e^{-\lambda t}\frac{\lambda^n t^n}{n!} + C e^{-\lambda t}
\end{aligned}
$$

Skoro $P_n(0) = 0$, to $C = 0$, zatem:

$$
P_n(t) = e^{-\lambda t}\frac{\lambda^n t^n}{n!} = e^{-\lambda t}\frac{(\lambda t)^n}{n!}
$$

□

Odpowiedź właściwa: Niech X_1 będzie pierwszym międzyczasem procesu Poissona N z parametrem λ. Zmienna $X_1 \mid N(t) = 1$ ma rozkład jednostajny na $[0, t]$.

Dowód.

$$
\begin{aligned}
P(X_1 < s \mid N(t) = 1) &= \frac{P(X_1 < s \cap N(t) = 1)}{P(N(t) = 1)} = \frac{P(N(s) = 1)\cdot P(N(t) - N(s) = 0)}{P(N(t) = 1)} \\
&= \frac{e^{-\lambda s}\lambda s \cdot e^{-\lambda(t-s)}}{e^{-\lambda t}\lambda t} = \frac{s}{t}.
\end{aligned}
$$

□

Centralne Twierdzenie Graniczne i mocniejsze warianty.

Rozkład normalny $\mathcal{N}(\mu, \sigma^2)$ – rozkład funkcji gęstości prawdopodobieństwa:

$$f_Z(z) = \frac{1}{\sigma\sqrt{2\pi}} e^{-((z-\mu)/\sigma)^2/2}$$

Dystrybuanta $\mathcal{N}(0,1)$ ozn. Φ

Ciąg dystrybuant $F_1, F_2, ...$ zbiega do dystrybuanty F (ozn. $F_n \to F$), jeśli dla każdego $a \in \mathbb{R}$, w którym F jest ciągła zachodzi:

$$\lim_{n\to\infty} F_n(a) = F(a)$$

Twierdzenie (Lévy-Cramér)**.** Niech $Y_1, Y_2, \ldots$ będzie ciągiem zmiennych losowych o dystrybuantach $F_1, F_2, \ldots$ i MFG $M_1, M_2, \ldots$. Niech Y będzie zmienną losową o dystrybuancie F i MFG M. Jeżeli dla każdego t zachodzi:

$$\lim_{n\to\infty} M_n(t) = M(t),$$

to $F_n \to F$ dla wszystkich t w których $F(t)$ jest ciągła.

Twierdzenie (Centralne Twierdzenie Graniczne)**.** Niech $X_1, X_2, \ldots, X_n$ będą i. i. d o średniej μ i wariancji σ^2. Niech $X_n = \frac{1}{n}\sum_{i=1}^n X_i$. Wówczas dla dowolnych $a,\ b$

$$\lim_{n\to\infty} \mathrm{P}\left(a \le \frac{X_n - \mu}{\sigma} \cdot \sqrt{n} \le b\right) \to \Phi(b) - \Phi(a)$$

Intuicyjnie: CTG mówi, że dla niezależnych zmiennych losowych (niekoniecznie i.d.) rozkład średniej wylosowanych wartości będzie zbiegać do rozkładu normalnego przy dużej liczby prób.

Dowód. Definiujemy $Z_i = (X_i - \mu)/\sigma$, wtedy $Z_i \perp Z_j$ dla $i \neq j$.

$$\mathbb{E}[Z_i] = \mathbb{E}\left[\frac{X_i - \mu}{\sigma}\right] = \frac{1}{\sigma} \cdot (\mathbb{E}[X_i] - \mathbb{E}[\mu]) = \frac{1}{\sigma} \cdot (\mu - \mu) = 0$$

$$\mathrm{Var}[Z_i] = \mathrm{Var}\left[\frac{X_i - \mu}{\sigma}\right] = \frac{1}{\sigma} \cdot (\mathrm{Var}[X_i - \mu]) = \frac{1}{\sigma} \cdot (\mathrm{Var}[X_i] - \mathrm{Var}[mu]) = \frac{1}{\sigma^2} \cdot \left(\sigma^2 - 0\right) = 1$$

$$\frac{\bar{X_n} - \mu}{\sigma} \cdot \sqrt{n} = \frac{\sqrt{n}}{n} \sum_{i=1}^n \frac{X_i - \mu}{\sigma} = \frac{\sqrt{n}}{n} \sum_{i=1}^n Z_i = \frac{\sum_{i=1}^n Z_i}{\sqrt{n}}$$

Żeby zastosować twierdzenie Lévy'ego-Craméra musimy pokazać, że MGF zmiennych losowych postaci

$$Y_n = \frac{\sum_{i=1}^n Z_i}{\sqrt{n}}$$

zbiega do MGF zmiennej losowej o standardowym rozkładzie normalnym, czyli:

$$\lim_{n\to\infty} M_{Y_n}(t) = \lim_{n\to\infty} \mathbb{E}\left[e^{t\sum_{i=1}^n Z_i/\sqrt{n}}\right] = e^{t^2/2}$$

Niech $M_{Z_i}(t) = \mathbb{E}\left[e^{tZ_i}\right]$ będzie funkcją tworzącą momenty zmiennej Z_i, wtedy:

$$M_{Z_i/\sqrt{n}}(t) = \mathbb{E}\left[e^{t\cdot Z_i/\sqrt{n}}\right] = M_{Z_i}\left(\frac{t}{\sqrt{n}}\right)$$

Ponieważ Z_i są niezależne i mają ten sam rozkład:

$$M_{Y_n}(t) = M_{\sum_i Z_i/\sqrt{n}}(t) = \left(M_{Z_i/\sqrt{n}}(t)\right)^n = \left(M_{Z_i}\left(\frac{t}{\sqrt{n}}\right)\right)^n$$

Definiujemy:

$$L(t) = \ln M_{Z_i}(t)$$

Liczymy pochodne:

$$M_{Z_i}(0) = 1 \implies L(0) = 0$$

$$L'(0) = (\ln M_{Z_i}(0))' = \frac{1}{M_{Z_i}(0)} \cdot M'_{Z_i}(0) = \frac{M'_{Z_i}(0)}{M_{Z_i}(0)} = \frac{\mathbb{E}[Z_i]}{1} = \mathbb{E}[Z_i] = 0$$

$$L''(0) = \frac{M_{Z_i}(0)M''_{Z_i}(0) - (M'_{Z_i}(0))^2}{(M_{Z_i}(0))^2} = \frac{M''_{Z_i}(0) - 0}{1} = \mathbb{E}\left[Z_i^2\right] = 1$$

Chcieliśmy pokazać, że:

$$\lim_{n\to\infty} M_{Y_n}(t) \to e^{t^2/2} \quad \text{równoważnie} \quad \lim_{n\to\infty}\left(M_{Z_i}\left(\frac{t}{\sqrt{n}}\right)\right)^n \to e^{t^2/2}$$

po zlogarytmowaniu stronami:

$$\lim_{n\to\infty} nL\left(\frac{t}{\sqrt{n}}\right) \to \frac{t^2}{2}$$

$$\lim_{n\to\infty} \frac{L\left(\frac{t}{\sqrt{n}}\right)}{n^{-1}} \to \frac{0}{0} \quad \textit{Alors L'Hôpitalisons-le!}$$

$$\begin{aligned}
\lim_{n\to\infty} \frac{L\left(\frac{t}{\sqrt{n}}\right)}{n^{-1}} &= \lim_{n\to\infty} \frac{-L'\left(\frac{t}{\sqrt{n}}\right)tn^{-\frac{3}{2}}}{-2n^{-2}} = \lim_{n\to\infty} \frac{L'\left(\frac{t}{\sqrt{n}}\right)t}{2n^{-\frac{1}{2}}} \\
&= \lim_{n\to\infty} \frac{-L''\left(\frac{t}{\sqrt{n}}\right)t^2n^{-\frac{3}{2}}}{-2n^{-\frac{3}{2}}} = \lim_{n\to\infty} \frac{t^2 \cdot L''\left(\frac{t}{\sqrt{n}}\right)}{2} = \lim_{n\to\infty} \frac{t^2 \cdot 1}{2} \\
&= \frac{t^2}{2}
\end{aligned}$$

□

Twierdzenie. Niech $X_1, \ldots, X_n$ będzie ciągiem niezależnych zmiennych losowych z $\mathbb{E}[X_i] = \mu_i$ i $\mathrm{Var}[X_i] = \sigma_i^2$. Niech zachodzi

1. $\exists_{M>0}\ \forall_{i\in[n]}\ P(|X_i| < M) = 1$
2. $\lim_{n\to\infty} \sum_{i=1}^n \sigma_i^2 = +\infty$.

Wówczas

$$P\left(a \le \frac{\sum_{i=1}^n (X_i - \mu_i)}{\sqrt{\sum_{i=1}^n \sigma_i^2}} \le b\right) \xrightarrow{D} \Phi(b) - \Phi(a).$$

Twierdzenie (Berry-Esséen)**.** Niech $X_1, \ldots, X_n$ będą i. i. d. o skończonej wartości oczekiwanej μ i wariancją σ^2. Dalej niech $\rho = \mathbb{E}\left[|X_i - \mu|^3\right] < \infty$ i $\overline{X}_n = \frac{1}{n}\sum_{i=1}^n X_i$. Istnieje taka stała C, dla której:

$$\left|P\left(\frac{\overline{X}_n - \mu}{\frac{\sigma}{\sqrt{n}}} \le a\right) - \Phi(a)\right| \le C \cdot \frac{\rho}{\sigma^3\sqrt{n}}.$$